

PLAN MAESTRO DE CATCH-UP DE IA Y MACHINE LEARNING

Decisiones canónicas, arquitectura aprobada, alcance y ruta de implementación

Punto de corte oficial

Este documento parte del estado cerrado en migración v30 y commit 64f380dd4adf0fa9462188401eabd5e228fec387. A partir de aquí se detiene la expansión de infraestructura determinista y comienza el catch-up formal de inteligencia artificial alrededor de identidad creativa, estrategia, guiones, análisis de contenido y aprendizaje continuo.

AS26 AI Lab | 29 de julio de 2026

Documento de referencia para decisiones futuras y prompts de Codex

Resumen ejecutivo

Veredicto

La base construida hasta v30 es útil y se conservará. El problema no fue construirla, sino haber retrasado la inteligencia generativa y semántica que el plan original contemplaba desde las primeras fases. El objetivo ahora es conectar un cerebro de IA controlado con la memoria, analítica, trazabilidad, seguridad y módulos ya existentes.

El producto seguirá siendo un copiloto estratégico y creativo para creadores de contenido. No será un editor automático de video. Acompañará el proceso completo antes y después de la edición: ideas, estrategia, guiones, empaquetado, análisis del video ya editado, detección de clips, copies, títulos, miniaturas, calendario, publicación asistida, medición y aprendizaje.

Decisiones maestras

- **Arquitectura híbrida:** procesamiento local como núcleo y uso selectivo de APIs.
- **Proveedores externos:** OpenAI y Anthropic, con un máximo normal de dos proveedores.
- **Modelos reemplazables:** los módulos usan roles de capacidad, no nombres fijos de modelos.
- **Memoria ligera:** no duplicar MP4 por defecto; conservar transcripciones, timestamps, metadatos, métricas, feedback y resultados.
- **Identidad privada:** la voz, humor, guiones y correcciones nunca se mezclan entre creadores.
- **Aprendizaje colectivo:** opcional, anónimo, estructurado y administrado en Supabase cuando existan usuarios suficientes.
- **Transcripción:** faster-whisper con large-v3-turbo como candidato equilibrado y large-v3 para máxima calidad o segmentos dudosos.
- **Embeddings:** locales; benchmark BGE-M3 contra multilingual-e5-large-instruct.
- **Calidad:** autenticidad humana objetivo de 7/10, reescritura medida, pruebas ciegas y puertas de salida.
- **Alcance pospuesto:** edición física, corte, montaje, efectos, mezcla y render automático del archivo de video.

Orden aprobado del catch-up

Bloque	Resultado principal
1. AI Runtime	Proveedores, roles, claves, costos, privacidad, caché, plantillas y trazabilidad.
2. Component Manager y transcripción	Instalación guiada, FFmpeg, modelos locales, benchmark y transcripción usable.
3. Creator Corpus	Fuentes ligeras, autenticidad, plataformas, etapas y permisos.
4. Semantic Retrieval	Embeddings locales, recuperación híbrida y CreatorContextBuilder.
5. Feedback Learning	Aprendizaje por ediciones, rechazos, confianza y confirmación humana.
6. Creator Voice Workbench	Primera prueba real de voz, hooks, copies y evaluación ciega.
7. IA en módulos existentes	Recommendations, Briefs, Outlines, guiones, video, clips, thumbnails, calendario y publicación.

Contenido

1. Motivo y contexto del catch-up
2. Biblia del producto y principios rectores
3. Alcance funcional definitivo
4. Arquitectura híbrida y proveedores
5. Corpus, almacenamiento y memoria ligera
6. Tres capas de conocimiento
7. Embeddings y recuperación semántica
8. Aprendizaje mediante correcciones
9. Evaluación de calidad y autenticidad
10. Orquestación, costos y privacidad
11. Transcripción de alta calidad y rendimiento
12. Componentes, instalación y onboarding
13. Credenciales, cuentas y ayuda al usuario
14. Aprendizaje colectivo y Supabase
15. Base universal de conocimiento
16. Plantillas, contexto y trazabilidad
17. Roadmap de implementación
18. Puertas de aceptación y riesgos
19. Siguiendo acción inmediata
- A. Registro compacto de decisiones canónicas

1. Motivo y contexto del catch-up

La especificación original definió al producto como un copiloto estratégico y creativo, no como un editor automático. Debía comprender progresivamente al creador, estudiar a la audiencia, analizar resultados reales, detectar oportunidades y convertir cada publicación en conocimiento reutilizable. La arquitectura inicial también contemplaba procesamiento local combinado con modelos por API para análisis narrativo, estrategia, lenguaje y visión.

Hasta la migración v30 se construyó una base extensa y valiosa: analítica, experimentos, memoria, lenguaje estructurado, audiencia, mercado, recomendaciones, planificación, briefs, outlines, preparación de producción, controles, snapshots, claims, derechos, conectores y trazabilidad. Sin embargo, la mayoría de esas capacidades seguían operando mediante reglas, estructuras y plantillas, sin el cerebro semántico y generativo que debía personalizar el producto.

Corrección de rumbo

No se desecha lo construido. Se utiliza como esqueleto, sistema nervioso, memoria y capa de control. El catch-up agrega el cerebro de IA y conecta la inteligencia generativa con la evidencia y restricciones existentes.

Qué se corrige

- Priorizar identidad creativa, guiones auténticos y aprendizaje real por encima de nuevas tablas o estados.
- Integrar IA en la cadena completa sin convertir el programa en un editor físico de video.
- Probar calidad con datos reales del creador, no declarar éxito porque un endpoint responde.
- Mantener costos bajos, privacidad local y control humano.
- Documentar toda decisión para que Codex no vuelva a improvisar arquitectura o alcance.

2. Biblia del producto y principios rectores

Fuentes de autoridad

1. Especificación funcional y técnica: IA Perfecta para Creador de Contenido - Heybermu Growth Copilot.
2. Plan de Acción: IA Perfecta para Creador de Contenido - ruta híbrida, local y económica.
3. Pilares canónicos acordados durante la auditoría.
4. Estado real del repositorio en v30 y commit de cierre.
5. Decisiones aprobadas en este documento.

Pilares canónicos

Pilar	Definición práctica
Inteligencia estratégica	Analizar métricas, audiencia, mercado, tendencias y experimentos; explicar evidencia e incertidumbre; maximizar probabilidades sin prometer viralidad.
Identidad creativa	Aprender tono, humor, vocabulario, ritmo, estructura, límites, hooks, remates y diferencias

Pilar	Definición práctica
	por plataforma.
Guiones auténticos	Prioridad creativa máxima. Deben necesitar cada vez menos reescritura y evitar voz genérica, artificial o ajena.
Aprendizaje continuo	Conservar fuentes, generado, editado, aprobado, rechazado, razones, contexto y resultados posteriores.
Costo y simplicidad	Procesar localmente, usar dos proveedores como máximo, caché, batch y modelos potentes solo cuando aporten valor.
Control humano	La IA propone y explica; el creador aprueba identidad, claims, derechos, producción y publicación.
Privacidad	Aislamiento por creator_id, consentimiento, minimización de datos y memoria oficial local.
ML futuro y prudente	RAG, embeddings y feedback primero. Fine-tuning o modelos predictivos solo con datos suficientes y justificación.

3. Alcance funcional definitivo

El producto sí acompañará

- Ideas, estrategia y oportunidades.
- Briefs, outlines, guiones, hooks, transiciones, remates y CTAs.
- Títulos, descriptions, captions, copies, hashtags y paquetes por plataforma.
- Conceptos y prompts de miniatura; análisis multimodal y relación con título y resultados.
- Análisis de videos largos ya editados y videos cortos terminados.
- Detección de candidatos a clips con timestamps, justificación, teaser, copy y adaptación por red.
- Notas de ritmo, claridad, estructura y oportunidades visuales sin modificar el archivo.
- Calendarización y horarios recomendados según audiencia y evidencia disponible.
- Preparación, borradores y publicación asistida o automática con aprobación explícita.
- Analítica posterior, post mortem, experimentos y aprendizaje para la siguiente pieza.

El producto no hará por ahora

- Cortar físicamente el video o exportar clips.
- Montar escenas, aplicar transiciones o efectos.
- Corregir color, mezclar audio o renderizar.
- Crear proyectos completos de Premiere, Resolve o Final Cut.
- Sustituir al editor humano.
- Entrenar un modelo fundacional propio.

Regla de alcance

Se pausa únicamente la edición física del archivo. La preproducción, la post-edición estratégica, la publicación y el aprendizaje permanecen dentro del producto.

4. Arquitectura híbrida y proveedores

La aplicación será local-first: archivos, transcripciones, memoria, métricas, embeddings, índices, resultados y feedback vivirán en la computadora. Las APIs recibirán únicamente el contexto necesario y autorizado para una tarea concreta.

Proveedores aprobados

Proveedor	Responsabilidades iniciales
OpenAI	Trabajo económico y estructurado, análisis general, multimodal, salidas estructuradas, fallback remoto de transcripción y generación alternativa.
Anthropic / Claude	Guiones, narrativa, reescritura de voz, copies creativos, crítica de autenticidad y segunda propuesta de alta importancia.

No habrá un ganador universal. Los modelos competirán por tarea y por creador mediante pruebas ciegas, autenticidad, reescritura, costo y cumplimiento.

Roles reemplazables

Rol lógico	Ejemplos de uso
cheap_structured_model	Clasificación, extracción, etiquetado, validación simple.
general_reasoning_model	Estrategia, analítica interpretativa, briefs y outlines.
creative_writing_model	Guiones, voz, narrativa y copies.
multimodal_model	Miniaturas, fotogramas y análisis visual.
transcription_fallback_model	Audio remoto cuando el equipo local no cumpla calidad o velocidad.
evaluation_model	Crítica secundaria, cumplimiento y comparación automática.

Regla de reemplazo

Los módulos nunca llamarán directamente a un nombre fijo de modelo. El catálogo central asignará modelos disponibles a roles. Si un modelo se retira, se cambia la asignación, se valida y se hace benchmark sin reescribir todo el producto.

5. Corpus, almacenamiento y memoria ligera

Política de archivos pesados

Creator Intelligence Studio no duplicará ni conservará permanentemente los MP4 por defecto. El usuario podrá mantener el archivo en su ubicación original o activar conservación explícita. Durante el análisis

pueden crearse audio, proxies, fotogramas y temporales; después se eliminan o se conservan solo cuando aporten valor.

Conservar de forma ligera	No conservar por defecto
Transcripción y timestamps	Copia permanente del MP4
Hash y referencia al archivo	Audio intermedio completo
Segmentos, escenas y estructura	Proxy temporal
Métricas y resultados	Todos los fotogramas extraídos
Títulos, copies y paquetes	Duplicados del mismo contenido
Feedback, versiones y diferencias	Cachés irrelevantes
Fotogramas esenciales comprimidos	Archivos de procesamiento descartables
Embeddings y metadatos	Recursos sin permiso o utilidad

Clasificación de muestras

Tipo	Uso
Oro	Escrito o hablado realmente por el creador y aún representativo.
Aprobado	Generado o sugerido y aceptado casi sin cambios.
Corregido	Versión de IA y versión final editada; fuente principal para aprender preferencias.
Rechazado	Ejemplo negativo con motivo; nunca se usa como voz positiva.
Externo	Referencia de mercado o estructura; jamás enseña la voz del creador.
Histórico	Representa una etapa anterior y recibe menor peso o exclusión.

Cada muestra guardará creator_id, plataforma, formato, tema, fecha, procedencia, autenticidad, estado, etapa creativa, permisos para API y relación con su fuente.

6. Tres capas de conocimiento

Capa	Contenido	Regla
Base universal	Marketing, community management, storytelling, analítica, experimentación, plataformas, derechos y seguridad.	Común para todos; orienta decisiones, no impone voz.
Inteligencia colectiva	Patrones anónimos por cohortes, nicho, plataforma, formato, tamaño y resultados relativos.	Opt-in, anonimización local y sin contenido privado.
Memoria privada	Voz, humor, vocabulario, guiones, correcciones,	Nunca se mezcla ni se comparte

Capa	Contenido	Regla
	límites, datos exactos y material no publicado.	entre creadores.

La evidencia propia del creador tendrá prioridad sobre promedios globales. Lo colectivo puede sugerir una prueba compatible, pero nunca ordenar que el creador copie una fórmula.

Ambición controlada

El aprendizaje colectivo inicial mejorará benchmarks, cohortes, pesos y recomendaciones. No se presentará como entrenamiento automático de un modelo global. Fine-tuning, ranking aprendido o entrenamiento federado se evaluarán únicamente cuando existan datos suficientes, consentimiento y controles.

7. Embeddings y recuperación semántica

Los embeddings se generarán localmente para mantener privacidad, evitar costo por indexación y no añadir un tercer proveedor. SQLite seguirá siendo la fuente principal y la similitud se calculará inicialmente en Python mediante una interfaz de VectorStore reemplazable.

Benchmark aprobado

Candidato	Rol en la prueba
BGE-M3	Candidato principal por recuperación multilingüe e híbrida.
multilingual-e5-large-instruct	Competidor para consultas instruidas y español multilingüe.

Solo se instalará permanentemente el ganador del benchmark. Cada vector conservará modelo, revisión, dimensión, hash de texto, versión de segmentación y fecha. Nunca se mezclarán vectores de modelos distintos.

Recuperación híbrida

1. Filtros exactos: creator_id, plataforma, formato, autenticidad, vigencia y permisos.
2. Búsqueda textual para nombres, expresiones, temas y coincidencias literales.
3. Búsqueda semántica para significado, humor, estructura y situaciones relacionadas.
4. Diversidad para evitar resultados repetidos.
5. Reranking y construcción de contexto según la tarea.

CreatorContextBuilder

Componente central que recibe la tarea, identifica creador/plataforma/formato, selecciona fuentes permitidas, recupera ejemplos positivos y negativos, separa identidad de evidencia estratégica, aplica presupuesto de tokens y registra exactamente qué contexto se envió.

Puerta	Objetivo inicial
Aislamiento por creador_id	100%
Exclusiones críticas	100%
Recall@5	80% o superior
Precision@5	70% o superior
Tiempo de búsqueda	Normalmente menor a 1 segundo

8. Aprendizaje mediante correcciones

El sistema aprenderá de diferencias verificables, no se reentrenará solo ni convertirá una corrección aislada en regla. Siempre conservará la salida generada, la versión final, el contexto usado, el proveedor, el modelo, el costo, la valoración y, cuando exista, el resultado posterior de la publicación.

Estado	Significado
Observación	Cambio aislado detectado.
Patrón candidato	Misma dirección en más de un caso.
Patrón repetido	Evidencia suficiente para sugerir preferencia.
Confirmado	El creador aprueba la preferencia.
Activo	Se aplica en tareas compatibles.
Obsoleto / reemplazado	Ya no representa el estilo actual.

Las preferencias se separarán por tarea, plataforma y formato. Un recurso puede ser válido para TikTok y resultar artificial en un video largo. Los cambios ortográficos, legales, de duración o por información nueva no se interpretarán automáticamente como voz.

Separación esencial

Preferencia creativa y rendimiento estratégico son señales distintas. Que un video tenga muchas vistas no convierte automáticamente una frase en parte de la identidad del creador.

9. Evaluación de calidad y autenticidad

La autoridad principal para determinar si un texto suena al creador será el propio creador. Los evaluadores automáticos aportarán señales secundarias y nunca reemplazarán esa decisión.

Dimensión	Cómo se evalúa
Autenticidad	Escala humana de 1 a 10; objetivo inicial promedio de 7/10.
Reescritura	Porcentaje y tipo de cambios entre generado y final.
Utilidad estratégica	Propuesta clara, evidencia, incertidumbre, riesgo y prueba sugerida.
Cumplimiento	Claims, derechos, privacidad, duración, plataforma, formato y palabras prohibidas.
Calidad creativa	Hook, claridad, originalidad, ritmo, progresión, remate y compatibilidad.
Resultado posterior	CTR, retención, finalización, compartidos, conversión y recurrencia dentro de cohortes comparables.

Benchmark ciego

OpenAI y Claude recibirán el mismo brief, contexto, restricciones y formato. La interfaz mostrará Versión A y Versión B sin revelar el proveedor. Se medirá autenticidad, reescritura, cumplimiento, costo y latencia. El ganador puede cambiar según tarea y creador.

Puerta de lenguaje	Meta
Autenticidad humana	$\geq 7/10$
Violaciones críticas	0
Reescritura promedio	Idealmente $< 40\%$
Trazabilidad	100% de ejecuciones
Resultados aprovechables	Mayoría clara del benchmark

10. Orquestación, costos y privacidad

Niveles de ejecución

Nivel	Uso
Local	Transcripción, segmentación, embeddings, estadísticas, diffs, validación, caché.
Económico	Clasificación, extracción, etiquetado, resúmenes y evaluaciones simples.
Creativo / estratégico	Guiones, voz, narrativa, análisis complejo y recomendaciones.
Comparación dual	Benchmarks, tareas importantes, rechazos o segunda opinión autorizada.

El AIOrchestrator seleccionará rol, proveedor y modelo según tarea, sensibilidad, calidad, presupuesto, permisos y latencia. La decisión será explicable y configurable.

Controles de gasto

- Presupuesto mensual y límite diario opcional.
- Costo máximo por tarea.
- Estimación antes de procesos importantes.
- Avisos al 50%, 75%, 90% y 100%.
- Bloqueo duro configurable.
- Registro de tokens, costo, latencia, reintentos y valoración.
- Caché por huella de modelo, plantilla, contexto y parámetros.
- Batch para trabajos no urgentes.
- Ningún fallback caro o entre proveedores sin permiso.

Privacidad por ejecución

Clase	Regla
Local únicamente	Nada sale del equipo.
API con texto seleccionado	Solo fragmentos autorizados.
API multimodal	Fotogramas o miniaturas seleccionadas.
Prohibido enviar	Material marcado como confidencial, sin permiso, con derechos pendientes o datos sensibles.

La memoria oficial será local. No se dependerá de threads remotos, vector stores alojados por proveedores ni archivos permanentes en APIs.

11. Transcripción de alta calidad y rendimiento

La transcripción alimenta voz, clips, timestamps y análisis narrativo. Debe cumplir calidad y velocidad al mismo tiempo. Local no significa mediocre, y máxima calidad no significa esperar horas por diez minutos de video.

Pila candidata aprobada

Componente	Decisión
Motor	faster-whisper
Modo equilibrado	large-v3-turbo
Máxima calidad	large-v3
CPU	Cuantización INT8
GPU	FP16 o INT8-FP16 según compatibilidad y VRAM
Fallback remoto	OpenAI, con autorización y costo visible
Diarización	Opcional; se activa cuando aporta valor

Modos y objetivos iniciales

Modo	Uso	Meta para 10 minutos
Rápido	Borrador y localización preliminar	2-5 min
Equilibrado	Corpus, clips y análisis normal	5-10 min
Máxima calidad	Audio difícil o corpus crítico	10-20 min

Estas metas se ajustarán al hardware, pero varias horas no serán aceptables como comportamiento normal. El sistema medirá el equipo, estimará tiempos y ofrecerá CPU, GPU o fallback remoto.

Calidad y revisión

- Benchmark con español mexicano, modismos, groserías, gaming, música, risas y múltiples voces.
- Glosario personal de nombres, juegos, personas, marcas, términos y muletillas.
- Detección de silencios, alucinaciones, incoherencias y segmentos de baja confianza.
- Reprocesamiento solo de segmentos dudosos con mayor calidad.
- Estados: verificada, alta, media, baja, requiere revisión o excluida del aprendizaje de voz.
- Ningún segmento dudoso enseña vocabulario exacto automáticamente.

Optimización

- Validación real de CUDA mediante inferencia.
- Paralelizar audio, escenas, fotogramas y metadatos cuando sea seguro.
- Hash de archivo para evitar reprocesamiento.
- Progreso real, ETA, pausa, cancelación y segundo plano.
- Caché por etapas y reanudación.
- Benchmark inicial del equipo con estimaciones para 10, 20 y 60 minutos.

12. Componentes, instalación y onboarding

La instalación debe ser autosuficiente. El cliente no instalará Python, pip, FFmpeg ni modelos desde páginas externas. El instalador incluirá el runtime base y la aplicación administrará componentes adicionales dentro de su propia interfaz, siempre que la licencia y compatibilidad lo permitan.

Instalador base

- Aplicación y runtime empaquetado.
- SQLite y librerías base.
- FFmpeg aprobado, versionado y con atribuciones.
- Credential Manager / keyring.
- Diagnóstico, gestor de modelos y reparación.
- Soporte CPU y modo local limitado.

Componentes opcionales administrados

- Transcripción equilibrada.

- Transcripción máxima calidad.
- Modelo ganador de embeddings.
- Runtime acelerado para NVIDIA cuando sea redistribuible.
- Diarización.
- Paquete offline futuro.

Onboarding obligatorio

La app base no fingirá estar completa. En el primer arranque mostrará componentes faltantes, tamaño, ubicación, tiempo, funciones habilitadas y funciones bloqueadas. Habrá un botón visible de Instalar recomendados y un modo limitado claramente señalado.

Visibilidad permanente

- Asistente en el primer arranque.
- Banner de Configuración incompleta en el inicio.
- Bloqueo explicativo antes de una función que requiere un componente.
- Configuración > Componentes locales para administrar, reparar, mover o eliminar.
- Estados claros: no instalado, descargando, instalado, actualización, incompatible, error o reparar.

Seguridad de descargas

- Origen aprobado y dominio oficial.
- Versión fijada.
- Hash criptográfico y tamaño esperado.
- Licencia registrada.
- Descarga reanudable.
- Verificación antes de instalar.
- Rollback y versión anterior conservada temporalmente.

13. Credenciales, cuentas y ayuda al usuario

Cada usuario pagará directamente su consumo de OpenAI y Anthropic y utilizará sus propias claves. AS26 no mantendrá un saldo central, no incluirá claves propias en el programa y no será responsable de financiar llamadas de clientes.

Almacenamiento de claves

- Ingreso desde la interfaz; no edición manual de .env para clientes.
- .env reservado a desarrollo y pruebas.
- Almacén seguro del sistema operativo mediante keyring / Credential Manager.
- SQLite guarda únicamente referencias y metadatos no secretos.
- Claves enmascaradas; reemplazar, probar o eliminar.
- Nunca aparecen en logs, backups, reportes ni soporte.

Ayuda integrada

Cada tarjeta de proveedor incluirá tutorial y botones oficiales para crear cuenta, administrar claves, comprar créditos, revisar facturación y consultar documentación. La interfaz explicará que una suscripción de ChatGPT o Claude no equivale necesariamente al saldo de API.

Elemento	Comportamiento
Crear cuenta	Abrir sitio oficial y mostrar dominio antes de salir.
API Keys	Abrir la sección oficial exacta para crear o administrar claves.
Billing / créditos	Abrir la página oficial de compra, recarga y saldo.
Tutorial	Pasos dentro de la app, con texto actualizable.
Probar conexión	Llamada mínima; validar permisos y modelos disponibles.
Saldo bajo	Mostrar consumo local siempre y saldo real solo cuando la API lo permita.
Sin créditos	Pausar la tarea, conservar progreso y ofrecer facturación o cambio autorizado.

Los enlaces vivirán en un catálogo central y se limitarán a dominios oficiales aprobados. La aplicación nunca pedirá contraseñas, tarjetas, cookies ni códigos de verificación.

14. Aprendizaje colectivo y Supabase

El aprendizaje colectivo será opcional y estará desactivado por defecto. La anonimización ocurrirá localmente antes del envío. La app compartirá únicamente señales estructuradas y agregables, nunca videos, audios, transcripciones, guiones, voz, títulos exactos, miniaturas, URLs, claves ni memoria privada.

Infraestructura aprobada

Supabase + PostgreSQL

Supabase será el proveedor inicial para datos globales. La aplicación no se conectará directamente a PostgreSQL ni contendrá claves administrativas. Todo envío pasará por una API de AS26 que validará esquema, consentimiento, tamaño, frecuencia y anonimización.

Dato permitido	Ejemplo
Contexto general	Plataforma, nicho agregado, formato, duración y rango de audiencia.
Patrón aplicado	Tipo de hook, estructura o recomendación codificada.
Resultado relativo	Percentil personal o cambio frente a cohorte propia.
Experimento	Variable, guardrails, resultado y confianza.
Uso del sistema	Recomendación aceptada, rechazada o modificada sin texto exacto.

Controles contra reidentificación

- Rangos, no cifras exactas.
- Percentiles o cambios relativos.
- Nichos agrupados cuando sean demasiado específicos.
- Sin textos ni URLs.
- Mínimo de cuentas antes de publicar benchmarks.
- Identificador aleatorio no derivado de correo, canal, hardware o claves.
- Separación entre cuenta/licencia e identidad anónima de contribución.

Conocimiento publicado

Las contribuciones crudas no serán consultables por clientes. AS26 agregará, revisará y publicará paquetes firmados y versionados de conocimiento colectivo. La app descargará la versión aprobada, validará hash/firma, conservará la anterior para rollback y podrá trabajar offline.

15. Base universal de conocimiento

Antes de que exista suficiente información personal o colectiva, todos los creadores tendrán una base común curada de marketing, community management, storytelling, analítica, plataformas, experimentación, seguridad y derechos. No será una colección de fórmulas virales.

Estructura de una entrada

- Principio y explicación.
- Aplicaciones y contextos donde suele ayudar.
- Qué no significa.
- Excepciones y contraejemplos.
- Plataformas, formatos y audiencia aplicables.
- Fuentes, fecha de vigencia y revisión.
- Confianza, estado y versión.

Jerarquía de fuentes

1. Documentación oficial de plataformas.
2. Investigación académica o técnica relevante.
3. Datos y experimentos propios del creador.
4. Patrones colectivos anónimos.
5. Referencias de mercado identificadas.
6. Conocimiento editorial curado por AS26.

Evitar homogeneización

La base universal explica qué problema revisar o qué principio considerar. La voz final sale de la memoria privada y del corpus auténtico. Así, todos reciben una educación estratégica común sin terminar hablando igual.

16. Plantillas, contexto y trazabilidad

Cada solicitud a OpenAI o Claude se construirá por capas y mediante plantillas versionadas. No habrá prompts gigantes dispersos en pantallas o módulos.

Capa	Contenido
1. Reglas centrales	No inventar evidencia, no copiar, no prometer viralidad, respetar privacidad y control humano.
2. Reglas de tarea	Plataforma, formato, objetivo, duración, estructura y operación: generar, revisar o adaptar.
3. Seguridad	Claims, derechos, datos sensibles, material no autorizado.
4. Memoria del creador	Preferencias activas, límites y etapa de estilo.
5. Corpus recuperado	Ejemplos auténticos, correcciones y negativos.
6. Evidencia estratégica	Analítica, experimentos, audiencia, tendencias y mercado.
7. Solicitud del usuario	Instrucción concreta y decisiones actuales.
8. Salida requerida	JSON, texto creativo, notas, riesgos y confianza.

Defensa ante contenido no confiable

Transcripciones, comentarios, páginas externas y metadatos se tratarán como datos delimitados, nunca como instrucciones. Esto reduce inyección de prompts y evita que una frase importada modifique las reglas del sistema.

Registro reproducible

- Tarea, plantilla y versión.
- Reglas centrales y versión.
- Fuentes y fragmentos recuperados.
- Conocimiento universal y colectivo usado.
- Proveedor, modelo exacto y parámetros.
- Costo, latencia, validaciones y reintentos.
- Resultado, feedback, versión final y desempeño posterior.

Las plantillas tendrán estados draft, testing, approved, deprecated y retired. Una nueva versión no reemplazará a la anterior sin benchmark, comparación de calidad y aprobación.

17. Roadmap de implementación

Bloque	Incluye	Criterio de salida
1. AI Runtime	Proveedores, roles, catálogo, keyring, costos, caché, privacidad, plantillas, validación y diagnóstico.	Agregar claves, probar proveedores, ejecutar llamada mínima, cambiar rol/modelo, registrar costo y evitar secretos en logs.

Bloque	Incluye	Criterio de salida
2. Component Manager y transcripción	FFmpeg, gestor interno, hardware, CUDA, faster-whisper, modos, progreso, caché y fallback.	Video real de 10-20 min transcrito con calidad/tiempo razonables, timestamps, dudas y sin MP4 duplicado.
3. Creator Corpus	Fuentes, autenticidad, aprobados/corregidos/rechazados, permisos, etapas y almacenamiento ligero.	Importar y clasificar muestras con aislamiento total.
4. Semantic Retrieval	Benchmark de embeddings, índices, filtros, diversidad y CreatorContextBuilder.	Puertas de Recall/Precision, aislamiento y tiempo.
5. Feedback Learning	Diffs, feedback, patrones, confianza, confirmación y métricas por proveedor.	Corrección evolucionada de observación a preferencia confirmada, nunca de un solo ejemplo.
6. Creator Voice Workbench	Análisis de voz, revisión, hooks, copies, comparación ciega y feedback.	Autenticidad $\geq 7/10$ y reescritura decreciente.
7. Integración progresiva	Recommendations, Briefs, Outlines, guiones, packaging, video, clips, thumbnails, calendario y publicación.	Cada módulo supera sus puertas de evidencia, calidad y seguridad antes de llamarse terminado.

Orden dentro de la integración progresiva

1. Recommendations.
2. Content Briefs.
3. Script Outlines.
4. Guiones completos guiados.
5. Títulos, copies, descriptions y captions.
6. Análisis narrativo de videos editados.
7. Candidatos a clips y paquetes por plataforma.
8. Thumbnail Lab multimodal.
9. Calendarización y horarios.
10. Publicación asistida o automática con aprobación.

18. Puertas de aceptación y riesgos

Puertas obligatorias

Área	Puerta
Seguridad	0 claves en logs; 0 cruces de creator_id; 0 acciones sensibles sin aprobación.
Voz	Autenticidad promedio $\geq 7/10$ y feedback humano como autoridad.
Retrieval	Aislamiento/exclusiones 100%; Recall@5 y Precision@5 según objetivo.
Transcripción	Calidad medida, dudas marcadas y rendimiento comercialmente razonable.

Área	Puerta
Costos	Estimación, presupuesto, registro, caché y bloqueo funcional.
Trazabilidad	Modelo, plantilla, contexto, fuentes, costos y resultado reproducibles.
Estrategia	Evidencia, confianza, incertidumbre y prueba propuesta; sin promesas.
Privacidad	Minimización de datos y consentimiento explícito para cualquier contribución.

Riesgos prioritarios

Riesgo	Prevención
Integración superficial de LLM	Corpus, retrieval, feedback, benchmarks y puertas antes de guiones completos.
Textos genéricos	Ejemplos auténticos, negativos, evaluación humana y aprendizaje por correcciones.
Costos impredecibles	Local-first, roles, caché, batch, estimación y límites duros.
Transcripción lenta o mala	Benchmark, modos, GPU real, reprocesamiento selectivo y fallback.
Dependencia de modelos retirados	Roles lógicos, catálogo, compatibilidad y benchmark de reemplazos.
Fuga de datos	Keyring, contexto mínimo, permisos por ejecución y memoria local.
Homogeneización de creadores	Voz privada separada de conocimiento universal y colectivo.
Construir servidor antes de tiempo	Preparar contratos y consentimiento; desplegar Supabase productivo cuando existan usuarios reales.

19. Siguiendo acción inmediata

Primero: consolidación documental en el repositorio

Antes de programar AI Runtime, Codex debe crear la biblia oficial dentro del repositorio. Esta fase será exclusivamente documental y no modificará lógica, migraciones ni comportamiento del producto.

Documentos a crear

Archivo	Propósito
docs/PROJECT_BIBLE.md	Visión, pilares, alcance, reglas de producto y autoridad de decisiones.
docs/AI_ML_ARCHITECTURE.md	Arquitectura híbrida, proveedores, roles, costos, privacidad, plantillas y trazabilidad.
docs/CREATOR_MEMORY_AND_LEARNING.md	Corpus, almacenamiento ligero, retrieval, feedback y aislamiento.

Archivo	Propósito
docs/ LOCAL_COMPONENTS_AND_TRANSCRIPTION. md	Instalación, FFmpeg, faster-whisper, modelos, hardware, calidad y velocidad.
docs/ COLLECTIVE_INTELLIGENCE_AND_PRIVACY. md	Tres capas, consentimiento, anonimización, Supabase y conocimiento global.
docs/AI_IMPLEMENTATION_ROADMAP.md	Bloques, orden, criterios de salida y capacidades pospuestas.

Después de revisar y aprobar esos documentos, se diseñará el contrato exacto de AI Runtime and Provider Orchestration Foundation: tablas, interfaces, pantallas, roles, credenciales, costos, migración v31, pruebas y exclusiones. Solo entonces se entregará a Codex el prompt de implementación.

Regla de gobernanza

Antes de cualquier prompt nuevo se comparará la decisión contra el plan original, los pilares, el estado real y el impacto sobre capacidades centrales. Si existe una duda o trade-off, se resolverá conjuntamente antes de programar.

Apéndice A. Registro compacto de decisiones canónicas

ID	Tema	Decisión
A01	Arquitectura	Híbrida y local-first.
A02	Proveedores	OpenAI y Anthropic; máximo normal de dos.
A03	Modelos	Asignación por roles; reemplazables y benchmarkeados.
A04	MP4	No duplicar ni conservar permanentemente por defecto.
A05	Corpus	Texto ligero, timestamps, metadatos, versiones y feedback.
A06	Identidad	Aislamiento estricto por creator_id.
A07	Conocimiento	Universal + colectivo anónimo + privado.
A08	Colectivo	Opt-in, anonimización local, sin voz ni textos privados.
A09	Supabase	Proveedor inicial para PostgreSQL global detrás de API AS26.
A10	Embeddings	Locales; BGE-M3 vs E5 benchmark.
A11	Vector store	SQLite + similitud Python inicialmente.
A12	Contexto	CreatorContextBuilder, pocos ejemplos relevantes y diversos.
A13	Feedback	Generado + final + diff + razón + madurez + confirmación.
A14	Calidad	Autenticidad humana meta 7/10 y reescritura medida.
A15	Benchmark	Pruebas ciegas por tarea y creador.
A16	Costos	Presupuestos, estimación, caché, batch y bloqueo.
A17	Privacidad	Memoria oficial local; contexto mínimo a APIs.
A18	Transcripción	faster-whisper; turbo equilibrado y large-v3 alta calidad.
A19	Velocidad	10 min no debe tardar horas; benchmark y reprocesamiento selectivo.
A20	Instalación	Autosuficiente, sin Python/pip/FFmpeg manual.
A21	Componentes	Gestor interno, recomendaciones y onboarding visible.
A22	Credenciales	Propias del usuario, keyring, nunca claves AS26.
A23	Ayuda	Enlaces oficiales y tutorial de cuenta, keys y créditos.
A24	Base universal	Curada, versionada, con fuentes, excepciones y confianza.
A25	Prompts	Plantillas por tarea, versionadas y trazables.
A26	Validación	Reglas locales después del modelo y reintentos limitados.
A27	Operaciones	Generar, revisar y adaptar son funciones distintas.
A28	Alcance	Pre y post edición sí; edición física/render no por ahora.
A29	Publicación	Asistida/automática con aprobación sigue en roadmap.

ID	Tema	Decisión
A30	Siguiente paso	Documentar, aprobar y luego AI Runtime v31.

Referencias de proyecto

- IA Perfecta para Creador de Contenido - Heybermu Growth Copilot. Especificación funcional y técnica, versión 2.0, julio de 2026.
- Plan de Acción IA Perfecta para Creador de Contenido - Heybermu Growth Copilot, versión 1.0, julio de 2026.
- Repositorio público Creator_Intelligence_Studio, estado cerrado en migración v30.
- Commit de cierre v30: 64f380dd4adf0fa9462188401eabd5e228fec387.
- Registro de decisiones aprobado por el usuario durante la auditoría y diseño del catch-up.

FIN DEL DOCUMENTO